

# 第十二章 Flink

## 第十二章考点

- Flink主要特性
- 流处理特点
- Flink理想框架
- Flink优势

## 1. Flink 概述与核心特性

### 1.1 什么是 Flink

- **定义**：Apache Flink 是一个分布式、高性能、高可用的开源**流处理框架**。
- **核心理念**：同时支持**实时计算**和**批量计算**（批流一体）。
- **起源**：起源于 Stratosphere 项目，实现了 Google Dataflow 流计算模型。

### 1.2 核心特性

1. **批流一体化**：将批处理看作是流处理的一种特殊情况（有界流）。
2. **高性能**：兼具**高吞吐**和**低延迟**。
3. **精确一次 (Exactly-once)**：提供状态一致性保障，确保数据不丢不重。
4. **状态管理**：支持 TB 级别的状态数据，支持有状态计算。
5. **事件时间 (Event Time)**：支持基于事件发生时间的处理，解决乱序问题。
6. **独立内存管理**：不完全依赖 JVM GC，通过序列化将对象转为二进制存储，有效利用内存。

### 1.3 架构演变

1. **传统数据处理架构**：
  - 中心化数据库存储事务数据。
  - **缺点**：数据库不堪重负，难以扩展。
2. **大数据 Lambda 架构**：
  - **双层架构**：批处理层 (MapReduce/Spark) + 实时处理层 (Storm/Spark Streaming)。
  - **缺点**：多套框架难管理，代码需要维护两套。
3. **流处理架构 (Flink 推崇)**：
  - 一方面，由于流处理架构中不存在一个大型集中式数据库，因此，避免了传统 数据处理架构中存在的“数据库不堪重负”的问题。
  - 另一方面，在流处理架构中，批处理被看成是流处理的一个子集，因此，就可 以用面向流处理的框架进行批处理，这样就可以用一个流处理框架来统一处理流 计算和批量计算，避免了Lambda架构中存在的“多个框架难管理”的问题题。

## 1.4 主流框架对比 (重点)

框架	延迟	吞吐量	一致性/容错	处理模型
Storm	极低	低	At-least-once (较弱)	逐条处理
Spark Streaming	秒级/高	高	Exactly-once	微批处理 (Micro-batch)
Flink	极低	高	Exactly-once (强)	逐条流式处理

- **结论：**Flink 是目前唯一同时满足高吞吐、低延迟、精确一次容错的理想框架。

## 1.5 Flink的优势

- 同时支持高吞吐、低延迟、高性能。
- 同时支持流处理和批处理
- 高度灵活的流式窗口。
- 支持有状态计算
- 具有良好的容错性
- 具有独立的内存管理：为了获得C一样的性能，Flink管理Java虚拟机内存。通过序列化与反序列化的方法将所有数据对象转换成二进制在内存中进行存储，能够降低数据存储空间，有效利用内存空间。
- 支持迭代和增量迭代。 增量迭代：对某些迭代而言，并不是单次迭代产生的下一次工作集中的每个元素都需要重新参与下一轮迭代，有时只需要重新计算部分数据同时选择性地更新解集。增量迭代能使一些算法执行得更高效。

# 2. Flink 的三大应用场景

## 2.1 事件驱动型应用 (Event-driven)

- **定义：**从事件流读取，根据事件触发计算、状态更新或外部动作。
- **典型案例：**反欺诈、异常检测、规则报警。
- **Flink 优势：**
  - **Savepoint (保存点)：**一致性的状态镜像，支持应用升级或扩容而不丢失状态。
  - **CEP 库：**复杂事件处理支持。

## 2.2 数据分析应用 (Data Analytics)

- **定义：**从原始数据提取信息（如报表、仪表盘）。
- **优势：**
  - 相比批量分析，流式分析延迟更低（实时洞察）。
  - 架构更简单（利用 Flink 的故障恢复机制，无需复杂的调度流水线）。
- **支持：**ANSI SQL 接口，批流一致的 SQL 语义。

## 2.3 数据流水线应用 (Data Pipeline)

- **定义**：类似 ETL，但以连续流模式执行，而非周期性触发。
  - **典型案例**：实时搜索索引构建、数据持续同步。
  - **优势**：降低数据迁移延迟。
  - **支持**：丰富的 Connectors (Kafka, JDBC, ES 等)。
- 

## 3. Flink 技术栈与编程模型

### 3.1 体系架构 (Master-Slave)

- **JobManager (Master)**：负责资源分配、任务调度、Checkpoint 协调。
- **TaskManager (Slave)**：负责具体的任务执行 (Task)，拥有独立的 JVM。

### 3.2 技术栈分层

1. **物理部署层**：Local, Cluster (Standalone, YARN), Cloud。
2. **Runtime 核心层**：分布式数据流引擎。
3. **API 层**：
  - **DataStream API**：用于流处理。
  - **DataSet API**：用于批处理。
4. **库层 (Libraries)**：
  - **CEP**：复杂事件处理。
  - **Table API & SQL**：关系型查询。
  - **Gelly**：图计算。
  - **FlinkML**：机器学习。

### 3.3 编程抽象级别 (由高到低)

1. **SQL** (最高层，声明式)。
  2. **Table API** (声明式 DSL)。
  3. **DataStream / DataSet API** (核心 API，通用性强)。
  4. **有状态数据流处理** (最底层，如 ProcessFunction，控制力最强)。
- 

## 5. 编程实践 (WordCount 逻辑)

### 5.1 开发流程

1. **环境准备**：安装 Java8+，安装 Maven。
2. **编写代码** (Maven 项目)。

3. 打包: `mvn package` 生成 JAR 包。
4. 提交任务: `./bin/flink run ...`。

## 5.2 核心代码逻辑 (Java)

一个标准的 Flink 程序包含以下步骤:

1. 获取执行环境:

```
ExecutionEnvironment env =  
ExecutionEnvironment.getExecutionEnvironment();
```

2. 加载/创建初始数据:

```
// 批处理读取文件  
DataSet<String> text = env.readTextFile("path/to/input");
```

3. 指定转换操作 (Transformation):

```
AggregateOperator counts = text  
    .flatMap(new WordCountTokenizer()) // 切分单词  
    .groupBy(0)                        // 按单词分组  
    .sum(1);                           // 统计频次
```

4. 指定计算结果输出 (Sink):

```
counts.print(); // 或 writeAsCsv
```

5. 触发程序执行 (流处理必须, 批处理视情况):

```
env.execute();
```

---

## 复习重点总结 (记忆口诀)

- **定位**: 批流一体, 低延迟高吞吐。
- **架构**: JobManager + TaskManager。
- **优势**: 对比 Spark Streaming 是真正的实时 (逐条), 对比 Storm 有状态和强一致性。
- **状态**: Checkpoints (容错), Savepoints (运维)。
- **API**: SQL > Table > DataStream/DataSet。